# Sprawozdanie 3

Kacper Dusza, INFORMATYKA, 131427

Zd.1

ex1.py × SMSSpamCollection.tsv

```python
import pandas as pd
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer


df = pd.read_csv(filepath_or_buffer: 'SMSSpamCollection.tsv', sep='\t', names=['label', 'message'])

sample_data = df['message'].head(10).tolist()

cv = CountVectorizer(stop_words='english')
cv_matrix = cv.fit_transform(sample_data)
df_cv = pd.DataFrame(cv_matrix.toarray(), columns=cv.get_feature_names_out())

print("COUNT VECTORIZER")
print(df_cv.iloc[:, :8])
print("\n" + "="*60 + "\n")

ngram_cv = CountVectorizer(ngram_range=(2, 2), stop_words='english')
ngram_matrix = ngram_cv.fit_transform(sample_data)
df_ngram = pd.DataFrame(ngram_matrix.toarray(), columns=ngram_cv.get_feature_names_out())

print("N-GRAM")
print(df_ngram.iloc[:, :5])
print("\n" + "="*60 + "\n")


tfidf = TfidfVectorizer(stop_words='english')
tfidf_matrix = tfidf.fit_transform(sample_data)
df_tfidf = pd.DataFrame(tfidf_matrix.toarray(), columns=tfidf.get_feature_names_out())

print("TF-IDF")
print(df_tfidf.iloc[:, :8].round(3))
```

COUNT VECTORIZER

| | 000 | 08002986030 | 08452810075over18 | 09061701461 | 100 | 11 | 12 | 150p |
|---|---|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| 2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 3 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 4 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 5 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 6 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 |
| 7 | 0 | 1 | 0 | 0 | 0 | 1 | 0 | 0 |
| 8 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 9 | 1 | 0 | 0 | 0 | 1 | 0 | 0 | 1 |

TF-IDF

| | 000 | 08002986030 | 08452810075over18 | ... | 11 | 12 | 150p |
|---|---|---|---|---|---|---|---|
| 0 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 1 | 0.000 | 0.00 | 0.2 | ... | 0.00 | 0.000 | 0.000 |
| 2 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 3 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 4 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 5 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 6 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.229 | 0.000 |
| 7 | 0.000 | 0.23 | 0.0 | ... | 0.23 | 0.000 | 0.000 |
| 8 | 0.000 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.000 |
| 9 | 0.223 | 0.00 | 0.0 | ... | 0.00 | 0.000 | 0.223 |

N-GRAM

| | 000 pounds | 09061701461 claim | 100 20 | 11 months | 12 hours |
|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 0 | 0 | 0 | 0 |
| 2 | 0 | 0 | 0 | 0 | 0 |
| 3 | 0 | 0 | 0 | 0 | 0 |
| 4 | 0 | 0 | 0 | 0 | 0 |
| 5 | 0 | 0 | 0 | 0 | 0 |
| 6 | 0 | 1 | 0 | 0 | 1 |
| 7 | 0 | 0 | 0 | 1 | 0 |
| 8 | 0 | 0 | 0 | 0 | 0 |
| 9 | 1 | 0 | 1 | 0 | 0 |

Zd.2

1. Która z metod mogłaby dać najlepsze wyniki w przypadku identyfikacji słów kluczowych w różnych dokumentach. Odpowiedź uzasadnij
2. Scharakteryzuj pojęcie Bag-of-Words
3. Jakie niedogodności niesie użycie macierzowej reprezentacji dokumentów tekstowych

1. TF-IDF dałby najlepsze wyniki. Metoda da skupia się wykrywaniu słów często występujących w danym dokumencie i jednocześnie przypisuje każdemu ze słów daną wagę. Dzięki temu automatycznie mamy usuwany szum, słowa typu: “oraz”, “i”, “dlatego” są eliminowane, co skutkuje efektywnym wykrywaniem słów kluczowych w danym dokumencie.

2. Metoda Bag-of-Words to metoda reprezentacji tekstu polegająca na traktowaniu dokumentu jako zbioru słów. Ignoruje ona kolejność słów oraz strukturę gramatyczną, jednak wszystkie słowa są zliczane.

   Przykładowo, mamy 2 dokumenty, gdzie w pierwszym mamy takie wartości: “Lubie jeść pizze”, a w drugim: “Lubie jeść bigos”. Powstaje nam tablica takich wartości tab = [‘Lubie’, ‘jeść’, ’pizze’, ‘hamburgery’]

   Reprezentacja obu tych dokumentów:

   Dok1: [1,1,1,0]
   Dok2: [1,1,0,1]

3. Możemy wymienić kilka problematycznych aspektów tego typu metod:

   - Większość dokumentów zawiera tylko ułamek słów z całego słownika. Powoduje to powstawanie ogromnych macierzy wypełnionych głównie zerami, co jest nieefektywne pamięciowo.

   - Przy dużych zbiorach danych słownik może liczyć setki tysięcy słów. Każde słowo to osobny wymiar, co drastycznie zwiększa złożoność obliczeniową.

   - Macierze nie oddają relacji między słowami. Wyrazy "zamek" (budowla) i "zamek" (w kurtce) są traktowane tak samo, a synonimy (np. "auto" i "samochód") są postrzegane jako całkowicie różne byty.

- Jeśli w nowym dokumencie pojawi się słowo, którego nie było w pierwotnym słowniku, macierz nie jest w stanie go zaindeksować bez przebudowania całego modelu.